PUC CAMPINAS
PONTIFÍCIA UNIVERSIDADE CATÓLICA

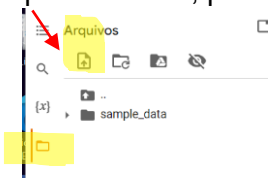
ESTATÍSTICA E ANÁLISE DE DADOS - 2º SEM 2026

Professores: Alexandre Monteiro, Bia Leite , Cintia Scrich, Geraldo Magela, Iara Fernandes, Wanessa Gazzon

EXPLORANDO A DISTRIBUIÇÃO NORMAL - PYTHON

➢ Carregamento do arquivo do Excel:

No lado esquerdo, clicar em arquivos e depois na seta , para fazer o upload



Após baixar o arquivo, o nome será exibido

1. Importando as bibliotecas do Python

1. Importar as bibliotecas

```
import pandas as pd
import numpy as np
import math
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
from scipy.stats import norm
import pylab
```

2. Leitura do arquivo de dados

Para utilizar o notebook com os seus dados, é necessário alterar o nome do arquivo do Excel, conforme ilustrado abaixo. Após digitar o nome do seu arquivo, o notebook armazena os dados na variável ***arquivo*** e todos os comandos serão executados com os dados do seu arquivo. Defina também a variável "coluna", especificando qual o nome dado na planilha para a variável que será analisada.

2. Defina a variável "arquivo" pelo nome do arquivo da planilha. Defina também a variável "coluna".

```
[ ]  arquivo = 'Tempo de Preenchimento.xlsx'
     coluna = 'Tempo'
```

3. Armazenamento dos dados

Leitura e armazenamento dos dados no python: é necessário definir uma variável para armazenar os dados do arquivo, no exemplo, escolhemos ***df.*** Ao digitar ***df*** na linha seguinte, a tabela armazenada é exibida.

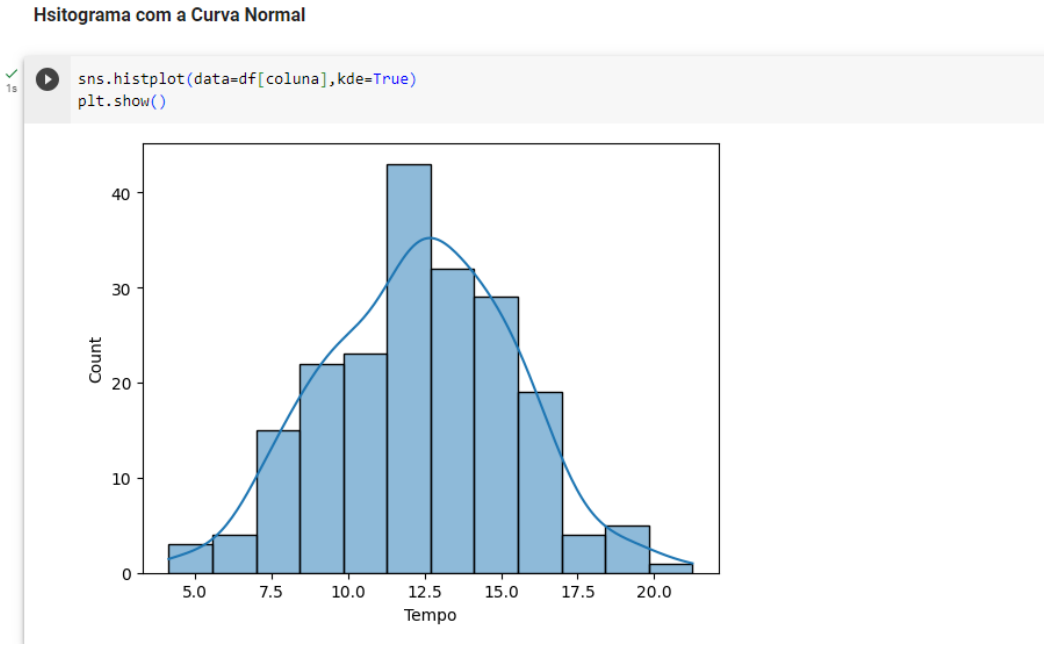
3. Leia a planilha no Phyton (para isso use o comando pd.read_excel(...)). Dê um nome (nesse caso chamaremos de "df").

```
[ ]  df=pd.read_excel(arquivo)
```

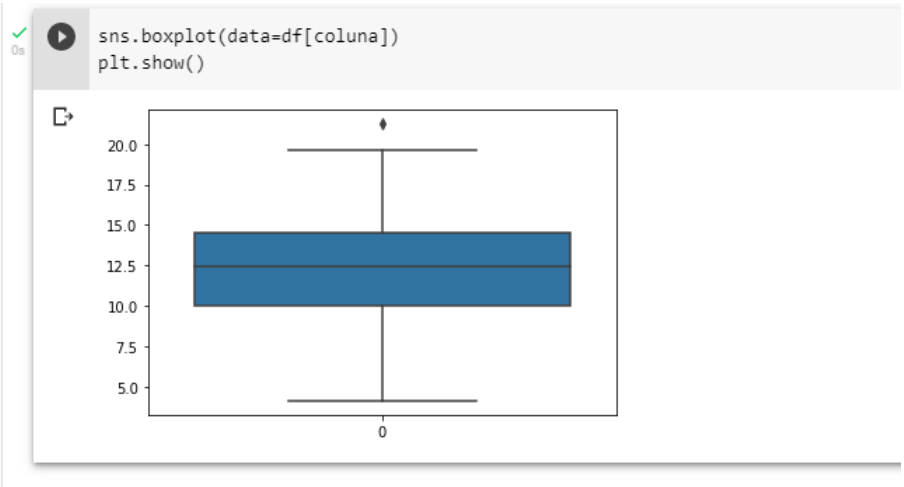
4. Gerar o histograma e o boxplot para variável contínua

4.1 Representação do histograma com a curva normal

Para montar o histograma basta fazer:



4.2 Boxplot



5. Cálculo da Média, Mediana e do Desvio Padrão

Veja os comandos necessários nos notebooks já disponibilizados no Projeto 1.

6. Testes de Normalidade

6.1 Análise do Histograma

6.1.1 Verificar único pico e analisar proximidade do mesmo com média e mediana (que devem ser próximas).

6.1.2 Calcular a proporção de dados nos intervalos $[\mu-\sigma,\mu+\sigma]$, $[\mu-2\sigma,\mu+2\sigma]$ e $[\mu-3\sigma,\mu+3\sigma]$

Definindo os limites de cada intervalo

```
[10] limite_inf1dp=round(media-dpad,2)
     limite_inf1dp

     9.28

     limite_inf2dp=round(media-2*dpad,2)
     limite_inf2dp

     6.21

[12] limite_inf3dp=round(media-3*dpad,2)
     limite_inf3dp

     3.14

[13] limite_sup1dp=round(media+dpad,2)
     limite_sup1dp

     15.42

[14] limite_sup2dp=round(media+2*dpad,2)
     limite_sup2dp

     18.49

[15] limite_sup3dp=round(media+3*dpad,2)
     limite_sup3dp

     21.56
```

Calculando a quantidade de dados em cada intervalo:

```
+ Código  + Texto

[16] quantidade_1dp=sum(i>=limite_inf1dp and i<= limite_sup1dp for i in df[coluna].sort_values())
     quantidade_1dp

     134

[17] quantidade_2dp=sum(i>=limite_inf2dp and i<= limite_sup2dp for i in df[coluna].sort_values())
     quantidade_2dp

     191

[18] quantidade_3dp=sum(i>=limite_inf3dp and i<= limite_sup3dp for i in df[coluna].sort_values())
     quantidade_3dp

     200
```

Calculando a proporção de dados em cada intervalo:

```
[19] #Porcentagem entre + - 1 desvio padrão
     porcentagem1 = round((quantidade_1dp/len(df[coluna]))*100,2)
     porcentagem1

     67.0

[20] #Porcentagem entre + - 2 desvios padrão
     porcentagem2 = round((quantidade_2dp/len(df[coluna]))*100,2)
     porcentagem2

     95.5

     #Porcentagem entre + - 3 desvios padrão
     porcentagem3 = round((quantidade_3dp/len(df[coluna]))*100,2)
     porcentagem3

     100.0
```

el: 85.18 GB

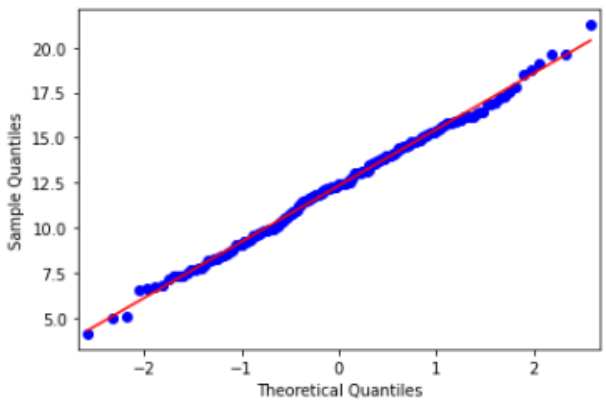
6.2 Análise do Boxplot

Verificar a simetria $Q2 - Q1 = Q3 - Q2$

Utilizar os comandos já apresentados nos notebooks disponibilizados para o Projeto 1

6.3 Gráfico Q-Q

```
sm.qqplot(df[coluna], line = 'r')
pylab.show()
```



7. Calculando a Probabilidade em Intervalos

Comandos para calcular a probabilidade da variável com distribuição normal assumir valores num intervalo:

Nos comandos abaixo: loc=média e scale=desvio padrão

```
# P(x<=14)
norm.cdf(14,loc=12.35,scale=3.07).round(4)
```

```
0.7045
```

```
# P(x>5)
1-norm.cdf(5,loc=12.35,scale=3.07).round(4)
```

```
0.9917
```

```
#Outra forma de calcular P(x>5)
norm.sf(5,loc=12.35,scale=3.07).round(4)
```

```
0.9917
```

```
# P(x>=8 e x<=11)
norm.cdf(11,loc=12.35,scale=3.07).round(4)-norm.cdf(8,loc=12.35,scale=3.07).round(4)
```

```
0.2518
```

```
# P(x>=a e x <=b)=0,9  Intervalo simétrico com 90% de probabilidade
[a,b]=norm.interval(0.9,loc=12.35, scale=3.07)
print(f'a={a:.2f}')
print(f'b={b:.2f}')
```

```
a=7.30
b=17.40
```

```
# P(x>=a)=0,15  Valor de x para os 15% maiores
# Como usa-se a f.d.p. acumulada temos que procurar os 85% menores
norm.ppf(0.85,loc=12.35,scale=3.07).round(2)
```

```
15.53
```

```
# P(x<=a)=0,10 Valor de x para os 10% menores
norm.ppf(0.10,loc=12.35,scale=3.07).round(2)
```

```
8.42
```